



ugr | Universidad
de Granada

TRABAJO FIN DE GRADO
GRADO EN INGENIERÍA INFORMÁTICA

Cuantificación de la incertidumbre de las
predicciones de modelos de aprendizaje
automático en problemas de estimación
del perfil biológico

Autor
David González Durán

Director
Pablo Mesejo Santiago

Mentor
Javier Venema Rodríguez



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

—
Granada, mes de 2025

Cuantificación de la incertidumbre de las predicciones de modelos de aprendizaje automático en problemas de estimación del perfil biológico

David González Durán

Palabras clave: palabra_clave1, palabra_clave2, palabra_clave3, ...

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Quantification of the uncertainty in machine learning model predictions for biological profile estimation problems

David González Durán

Keywords: Keyword1, Keyword2, Keyword3, ...

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Yo, **David González Durán**, alumno de la titulación **TITULACIÓN de la Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 32071015E, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: David González Durán

Granada, a X de mes de 202.

D. **Pablo Mesejo Santiago**, Profesor del Área de XXXX del Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

D. **Javier Vénema Rodríguez**, Esdudiente de Doctorado del programa de Tecnologías de la Información y de la Comunicación e investigador en Inteligencia Artificial en Panacea Cooperative Research.

Informan:

Que el presente trabajo, titulado *Cuantificación de la incertidumbre de las predicciones de modelos de aprendizaje automático en problemas de estimación del perfil biológico*, ha sido realizado bajo su supervisión por **David González Durán**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a X de mes de 2025.

Los directores:

Pablo Mesejo Santiago

Javier Vénema Rodríguez

Agradecimientos

Poner aquí agradecimientos...

Índice general

1. Introducción	1
1.1. Descripción del problema	1
1.1.1. Identificación humana y estimación del perfil biológico	2
1.2. Motivación	5
1.3. Objetivos	7
1.4. Planificación temporal del proyecto	9
1.5. Presupuesto del proyecto	14

Índice de figuras

1.1.	Procedimiento secuencial para la identificación forense basada en el esqueleto humano (<i>skeleton-based forensic identification</i>) [20].	4
1.2.	Línea de regresión del modelo de regresión propuesto en [33] que predice la estatura a partir de la longitud de la tibia.	6
1.3.	Evolución de hallazgos/identificación de cadáveres en España (2010-2024) [39].	7
1.4.	Evolución del número de diligencias preprocesales de determinación de edad abiertas en España (2011–2023). Elaboración propia a partir de [41-44].	8
1.5.	Diagrama de modelo de regresión que usa predicción conformal, el cual, además de proporcionar una estimación puntual del valor esperado, entrega un intervalo de predicción con un nivel de confianza del 95 %.	9
1.6.	Diagrama de Gantt inicial del proyecto	10
1.7.	Diagrama de Gantt final del proyecto	11

Índice de tablas

Capítulo 1

Introducción

1.1. Descripción del problema

La antropología es la ciencia que estudia la humanidad en todas sus dimensiones: biológica, cultural, lingüística o arqueológica [1], a lo largo del tiempo y en distintas partes del mundo. La antropología biológica o física se centra en el estudio de la anatomía, el crecimiento, la adaptación y la evolución del cuerpo humano [2]. Dentro de este campo, la **antropología forense (AF)** es el subcampo especializado que aplica métodos y técnicas antropológicas para resolver cuestiones médico-legales [2], empleando conocimientos de antropología física, aunque a veces también de la arqueología, para la correcta recuperación y análisis de la evidencia forense. Aunque tradicionalmente asociada al estudio de restos humanos esqueletizados o en descomposición, la AF también contribuye a la estimación del perfil biológico en individuos vivos, especialmente en contextos legales.

Tradicionalmente, los antropólogos forenses han tenido cinco principales objetivos en su trabajo [3]:

1. Determinar el **perfil biológico** de un individuo (es decir, sexo, edad, estatura y ascendencia), ya sea en restos esqueletizados donde los tejidos blandos se han deteriorado hasta el punto de que estas características no pueden determinarse mediante inspección visual, o en personas vivas mediante técnicas no invasivas como análisis radiográficos o morfológicos.
2. Identificar la naturaleza de lesiones traumáticas (como heridas de bala, puñaladas o fracturas) en huesos humanos, así como sus causantes, con el objetivo de recopilar información sobre la causa y circunstancias de la muerte.

3. Estimar el intervalo *post mortem*, es decir, el tiempo transcurrido desde la muerte, gracias a su conocimiento sobre los procesos de descomposición corporal.
4. Asistir en la localización, recuperación y conservación de los restos (superficiales o enterrados) aplicando técnicas arqueológicas, garantizando la recolección de toda la evidencia forense relevante.
5. Proporcionar información clave para la **identificación** de los fallecidos, basándose en las características distintivas de los esqueletos.

Además de estos roles, en la actualidad los antropólogos desempeñan otros trabajos que no están relacionados con el ámbito criminalístico. Entre ellos, uno de sus campos de acción más relevantes es la **identificación de víctimas en contextos de catástrofes masivas** [4-6], como accidentes aéreos, ataques terroristas o desastres naturales, donde los restos suelen estar mutilados o desfigurados.

Su labor también es fundamental en la **recuperación e identificación de violaciones sistemáticas de derechos humanos**, como exterminios, persecuciones políticas y represiones dictatoriales [7]. Casos como la Guerra Civil Española y la Dictadura Franquista [8, 9], así como las múltiples dictaduras en el Cono Sur de América [10], han requerido la intervención de equipos forenses para esclarecer la verdad histórica y restituir la identidad de las víctimas a sus familiares, contribuyendo al proceso de memoria, justicia y reparación para las familias afectadas. Esta vinculación con la justicia trasciende lo nacional: la ciencia forense es clave en la **investigación de crímenes de guerra contra poblaciones civiles**. Organizaciones como Médicos por los Derechos Humanos y la ONU financian equipos especializados que documentan estos crímenes, proporcionando pruebas esenciales para tribunales internacionales [11].

Y por último, también son fundamentales para **estimar la edad de personas vivas en casos legales**, especialmente cuando no existen registros confiables. Esto ocurre, por ejemplo, en casos de solicitudes de asilo, adopciones internacionales o procesos judiciales donde es necesario determinar si una persona es menor o mayor de edad, lo cual puede tener importantes implicaciones legales. Según el tipo de procedimiento, se puede requerir tanto la estimación de la edad mínima como la edad más probable del individuo, con el fin de priorizar la protección de los menores, evitando que queden expuestos a violaciones de sus derechos.

1.1.1. Identificación humana y estimación del perfil biológico

Como hemos visto, la **identificación humana (ID)** es una de las principales tareas que aborda la AF. Consiste en la determinación y verificación

de la identidad de una persona en base a [12]: evidencias circunstanciales (hora y lugar del descubrimiento del cuerpo, efectos personales, confirmación visual por parte de familiares y amigos); y evidencias físicas, obtenidas a través de examinación externa de características como el sexo, color de piel, tatuajes, o huellas dactilares, o, cuando estas no estén disponibles, mediante examinación interna con técnicas médico-científicas, donde se aplican técnicas de antropología y genética forense.

Cabe destacar que, aunque los análisis dactilares y genéticos superan en precisión identificativa a los métodos antropológicos, su aplicabilidad enfrenta limitaciones técnicas significativas que condicionan su uso en ciertos contextos forenses [6]. Las huellas dactilares requieren de: tejido blando preservado, lo que es común en cadáveres frescos, pero se pierde con la descomposición o la carbonización; y una base de datos que incluya la huella del individuo en vida (registros *ante mortem*). Por otro lado, en cuanto al análisis genético, este puede verse comprometido por una mala conservación del ADN que puede deberse a su degradación o contaminación. La concentración presente en un cadáver se reduce drásticamente en los primeros 8 meses *post mortem* [13], y factores como las altas temperaturas, la exposición a humedad ambiental o la presencia de aguas subterráneas y entornos ricos en oxígeno, que fomentan la presencia microbiana, perjudican la conservación del ADN [14]. Y, aún extraída una secuencia válida de ADN, se necesita de muestras con las que compararla, a ser posible de familiares de primer grado, para establecer una identificación concluyente.

Por tanto, la AF contribuye al problema de identificación humana en dos escenarios [15]:

1. Cuando los otros métodos no son viables, dado que las pruebas no se puedan recoger o no sean válidas, o no haya registros con los que compararlas.
2. Como apoyo a otras técnicas de identificación. Por ejemplo, las técnicas de estimación del perfil biológico pueden reducir el grupo de posibles coincidencias en bases de datos genéticos, facilitando el cotejo de secuencias genéticas y reduciendo el coste del proceso.

La **estimación del perfil biológico (PB)** es, por tanto, un proceso fundamental de la AF, en el cual se determinan características biológicas clave de un individuo [3]:

- **sexo**, mediante el análisis morfológico y métrico de rasgos sexuales en el esqueleto, especialmente en la pelvis y el cráneo;

- **edad**, estimada a partir de cambios morfológicos y de desarrollo en el esqueleto, pudiendo referirse tanto a la **edad al momento de la muerte** en restos óseos, como a la **edad cronológica**¹ en personas vivas en contextos forenses o humanitarios;
- **estatura**, mediante la estimación de la talla a partir de longitudes óseas, particularmente de los huesos largos; y
- **ascendencia o afinidad poblacional**, analizando variaciones craneométricas y morfológicas asociadas a poblaciones o grupos geográficos (actualmente en revisión [17-19]).

En los problemas de ID, cuando estas características biológicas coinciden con los registros *ante mortem*, se fortalece la hipótesis de identificación; en cambio, si existen una o más discrepancias —especialmente de alguna característica firme como múltiples epífisis no fusionadas, que no pueden ocurrir en un adulto mayor—, el individuo es excluido como posible coincidencia [3]. En la Figura 1.1 podemos observar que la estimación del PB es uno de los primeros pasos en el proceso de ID forense.

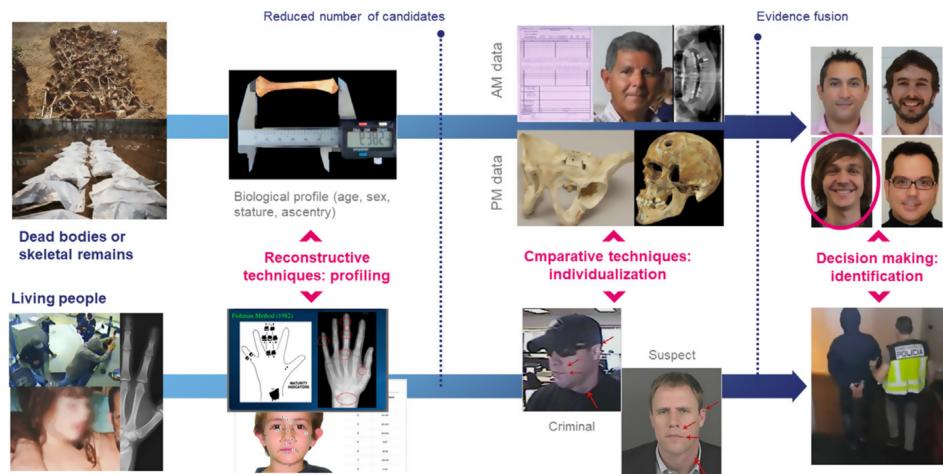


Figura 1.1: Procedimiento secuencial para la identificación forense basada en el esqueleto humano (*skeleton-based forensic identification*) [20].

La estimación del PB en restos humanos es una tarea compleja, especialmente cuando se estima la edad en el momento de la muerte, ya que hay diferentes métodos a aplicar dependiendo de la fase de desarrollo del individuo. Las variaciones en la morfología de los huesos son bien conocidas, pero estas no siempre ocurren al mismo tiempo en diferentes individuos, ya que no están expuestos a las mismas condiciones genéticas y del entorno.

¹La edad cronológica es la edad real de una persona desde su nacimiento, mientras que la edad biológica o fisiológica refleja la condición fisiológica del cuerpo [16].

Además, como se ha mencionado anteriormente, la estimación de edad también se realiza sobre personas vivas en casos legales donde la edad es un factor determinante [21], por ejemplo, con menores migrantes no acompañados. En estos casos no se tiene acceso a los huesos de la persona de forma directa, por lo que el análisis se realiza sobre imágenes médicas.

1.2. Motivación

Los métodos de estimación del PB se basan en la evaluación visual y en el análisis morfométrico de rasgos esqueléticos, que requieren de conocimiento especializado. Sin embargo, su aplicación puede presentar ambigüedades en su formulación que den lugar a interinterpretaciones variables —muchas veces fruto de sesgos cognitivos [22, 23]— y están sujetos a posibles errores de medición [24]. Además, la gran variabilidad genética y ambiental entre individuos, que afecta la morfología del esqueleto y genera diferencias significativas entre poblaciones de distintas regiones [25], hace que muchos de estos métodos —basados en muestras de referencia limitadas o no representativas de la diversidad humana global— pierdan precisión. Esto puede introducir sesgos al estimar el PB de individuos de grupos poco estudiados o con características atípicas.

Frente a estas limitaciones, recientes avances en inteligencia artificial (IA) y *machine learning* (ML) han demostrado el potencial de mejorar la exactitud y objetividad de estimación del PB, tanto para la estimación de sexo [26-28] como de edad [29-31].

Sin embargo, aún mejorando la exactitud de las predicciones, los modelos siguen mostrando carencias respecto a la cuantificación de incertidumbre, pues no todas las predicciones tienen el mismo nivel de confianza o fiabilidad. Ya en [32] se introducía no solo la necesidad de identificar el método adecuado para estimar la edad a partir de los elementos disponibles, sino también de evaluar su confiabilidad y realizar un estudio del error arrojado por las predicciones del método. Estos generalmente se han basado en la estadística frequentista² [33-35]. Un ejemplo de este tipo de análisis se ilustra en la Figura 1.2, donde se examina la distribución probabilística del error residual arrojado por el modelo de regresión propuesto en [33].

Aunque existen métricas para evaluar el error cuando se dispone de *ground truth*, la mayoría de los modelos actuales se limitan a ofrecer predicciones puntuales en regresión [34, 36, 37] o etiquetas únicas en clasificación [36, 38], sin cuantificar la incertidumbre asociada a cada predicción.

²La estadística frequentista es la corriente que se desarrolla a partir de los conceptos de probabilidad y que se centra en el cálculo de probabilidades y el contraste de hipótesis.

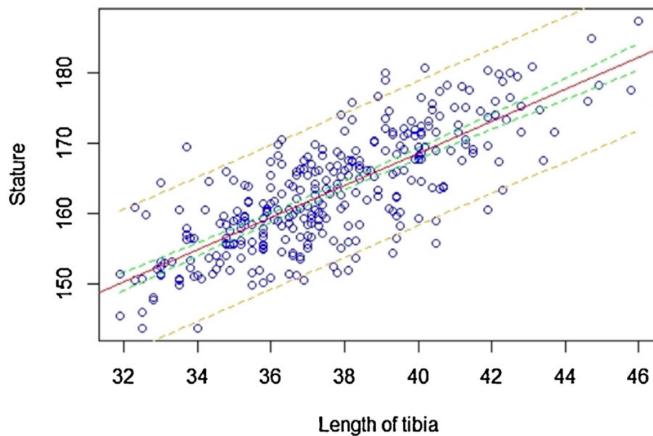


Figura 1.2: Línea de regresión del modelo de regresión propuesto en [33] que predice la estatura a partir de la longitud de la tibia. En rojo, la línea de regresión; en verde, la línea de los intervalos de confianza del 95 %; y en naranja, la línea de los intervalos de predicción al 95 % de confianza.

Con lo anterior se expone la motivación de la aplicación de ML a la AF, así como de la necesidad de cuantificar la incertidumbre en las predicciones, para ofrecer garantías de confiabilidad estadística que aspiren a sustentar la validez legal en contextos judiciales. Algunos datos que magnifican la necesidad de técnicas de AF confiables actualmente son:

- En los últimos años, ha aumentado significativamente el número de cadáveres hallados en el territorio español, como podemos apreciar en la Figura 1.3 [39]. En 2024 se ha alcanzado una cifra record, —en gran parte debido a las inundaciones de la DANA Valencia—, de 531 cadáveres en 2024, de los cuales se pudo identificar a 323.
- En 2020, de las 2.457 fosas totales documentadas de la Guerra Civil y el franquismo, aún 1.221 seguían sin ser intervenidas y se estimaba que “con una intervención oficial del Estado podrían recuperarse unos 20 a 25.000 individuos” e identificar “entre 5 y 7.000 de ellos”, estimándose necesario contar con unos 40-50 profesionales de la antropología forense [40].
- En España, se ha registrado en la última década (2013-2023) un aumento significativo en la llegada de Menores Extranjeros No Acompañados [41-44], que ha disparado consigo el número de diligencias abiertas para la determinación de su edad, como se ve reflejado en la Figura 1.4.
- La relevancia de la ciencia forense en la identificación de víctimas y la protección de la dignidad humana ha convertido su aplicación en un

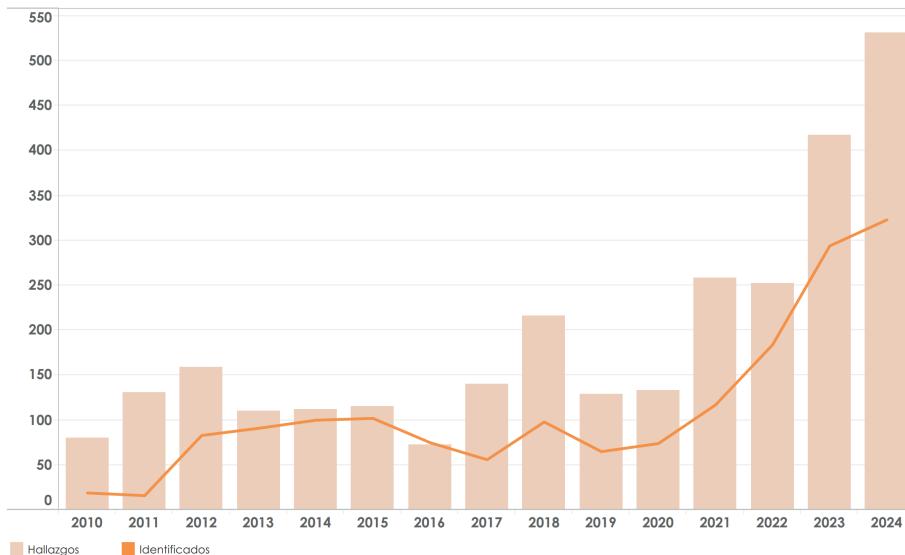


Figura 1.3: Evolución de hallazgos/identificación de cadáveres en España (2010-2024) [39].

pilar fundamental de los derechos humanos y la justicia internacional, naciendo así la **acción forense humanitaria** [45]. Esta disciplina emplea la ciencia forense con un propósito exclusivamente humanitario, con los objetivos de: identificar a las personas fallecidas, gestionar dignamente sus restos y aliviar el sufrimiento de sus familias en situaciones de conflicto, migración y desastres naturales [46].

1.3. Objetivos

La **predicción conformal** emerge como un marco teórico robusto para generar intervalos de predicción con garantías estadísticas sólidas, independientemente de la distribución subyacente de los datos. A diferencia de los enfoques tradicionales, este método no solo ofrece predicciones puntuales sino que cuantifica la incertidumbre asociada a cada estimación mediante intervalos o conjuntos de predicción que reflejan la confiabilidad de la predicción en cada caso particular.

Este Trabajo de Fin de Grado tiene un doble objetivo:

- desde un prisma teórico, defender la cuantificación de incertidumbre como herramienta esencial en ML, ofrecer un panorama de métodos destacados, analizando sus ventajas y limitaciones, y centrarnos en la predicción conformal y sus técnicas más populares.

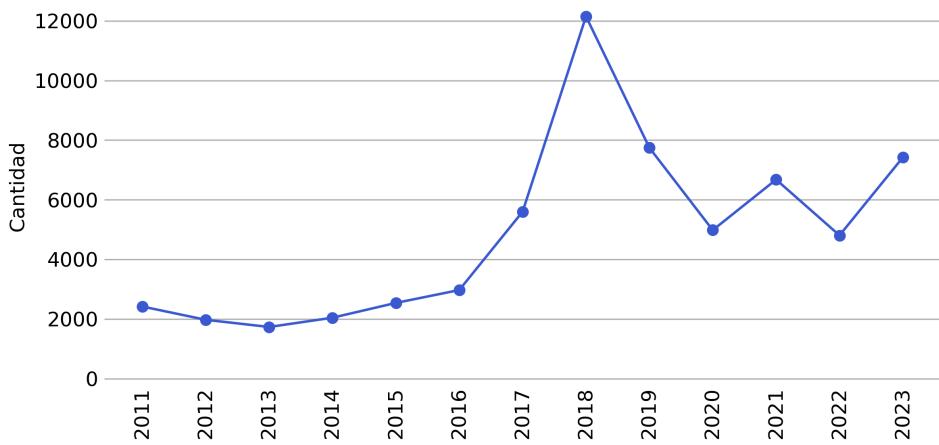


Figura 1.4: Evolución del número de diligencias preprocesales de determinación de edad abiertas en España (2011–2023). Elaboración propia a partir de [41–44].

- aplicar la predicción conformal a un contexto práctico como es el problema de estimación del PB, centrándose en la estimación de edad y de sexo a partir de datos biológicos e imágenes médicas.

De esta forma, podremos incorporar la incertidumbre propia del problema a resolver y del modelo entrenado para él, para, en aquellos casos más confusos, devolver conjuntos de predicciones con más de una etiqueta predicha (p.ej., {masculino, femenino}) en problemas de clasificación, o intervalos de predicción más amplios (p.ej., $\text{edad} \in [16,20]$) en problemas de regresión, en ambos casos para un nivel de confianza determinado.

Por tanto, podemos desgranar los objetivos en:

- Estudiar de forma exhaustiva la bibliografía sobre predicción conformal y sus diversas variantes, así como de la estimación de sexo y edad, centrando nuestra atención en el estado del arte.
- Implementar, entrenar y validar modelos de regresión —en problemas de estimación de edad— y clasificación —tanto en problema de estimación de sexo como edad legal— a los que aplicar la inferencia conformal.
- Comparar los intervalos y conjuntos de predicciones generados para evaluar su calibración empírica, robustez ante datos ambiguos y utilidad forense, contrastándolos con métodos tradicionales (p.ej., intervalos de confianza clásicos).

- Realiza una primera aproximación a un marco interpretable y con garantías estadísticas para la estimación del perfil biológico (véase un ejemplo práctico en la Figura 1.5), donde la incertidumbre cuantificada pueda integrarse en informes periciales bajo estándares jurídicos.

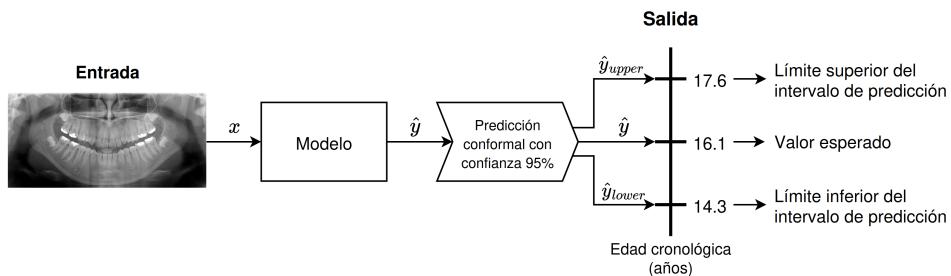


Figura 1.5: Diagrama de modelo de regresión que usa predicción conformal, el cual, además de proporcionar una estimación puntual del valor esperado, entrega un intervalo de predicción con un nivel de confianza del 95 %. Esta salida se lee de la siguiente manera: “la edad esperada del individuo es de 16.1 años y, con una confianza del 95 %, la edad real del individuo está entre los 14.3 y los 17.6 años”.

En resumen, este trabajo pretende explorar la integración de marcos probabilísticos en la práctica forense que capturen la incertidumbre de los problemas, y facilitar el uso de la inferencia conformal en ellos. Este enfoque proporciona estimaciones calibradas de incertidumbre, con garantías estadísticas de contener el valor real en un conjunto o intervalo de predicción, útiles para la toma de decisiones fundamentadas en contextos prácticos donde la interpretabilidad y robustez son críticas.

1.4. Planificación temporal del proyecto

Partimos de que el Proyecto de Fin de Grado tiene asignado 12 créditos ECTS, lo que equivale a 300 horas de trabajo. Estas 300 horas se distribuyen a lo largo del segundo cuatrimestre del curso 2024/2025, constando de 66 días lectivos, lo que resulta en una carga de trabajo de aproximadamente 4.54 horas al día. La planificación inicial del proyecto se presenta en el diagrama de Gantt de la Figura 1.6.

No obstante, debido a ajustes en la orientación conceptual del trabajo, modificaciones en el enfoque metodológico y determinadas circunstancias personales de salud, fue necesario realizar cambios sobre la planificación inicial, posponiéndose finalmente la entrega del TFG al mes de septiembre.

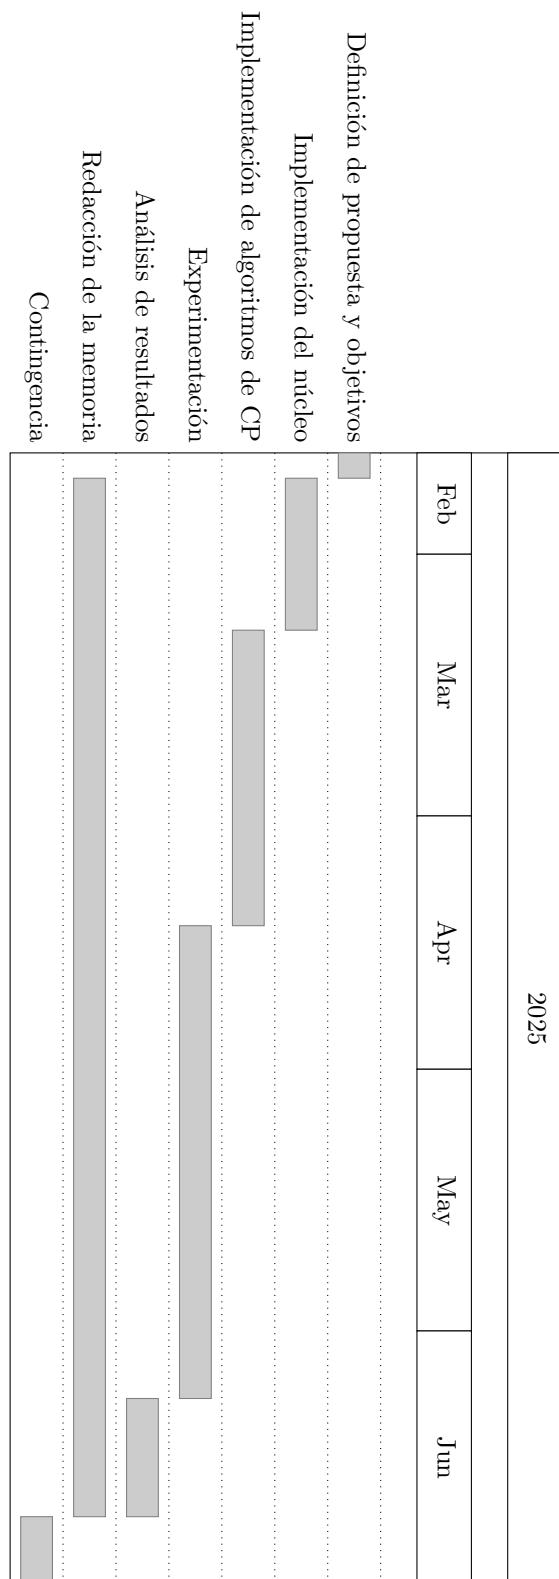


Figura 1.6: Diagrama de Gantt inicial del proyecto

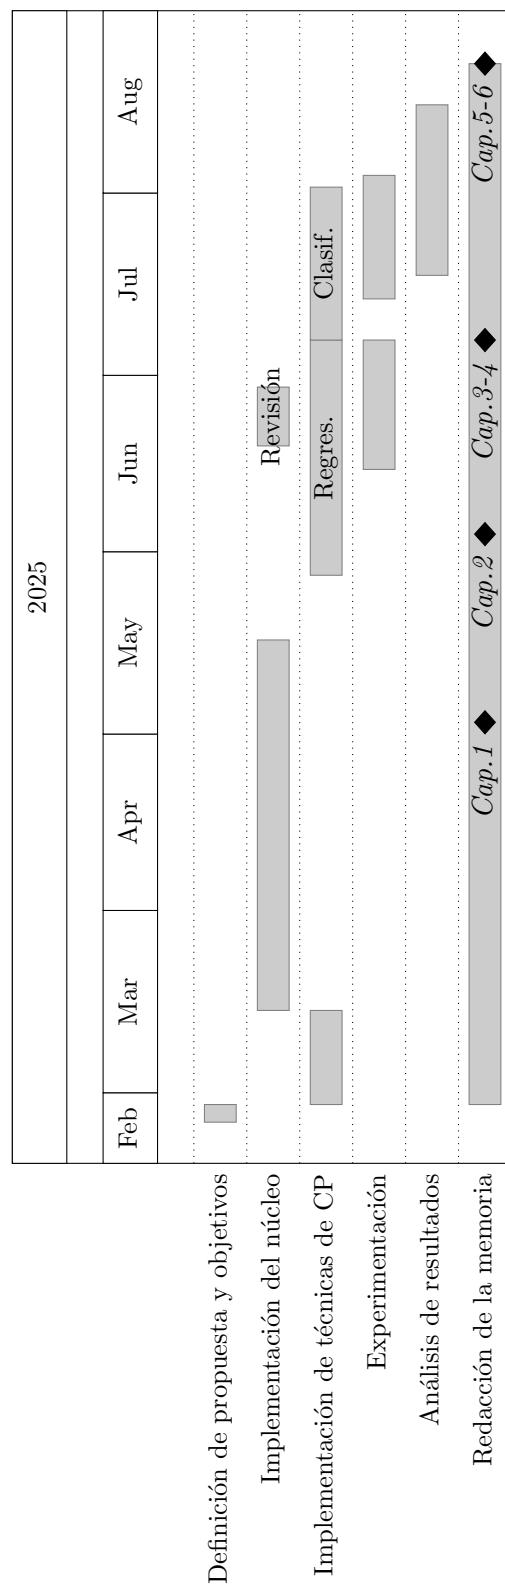


Figura 1.7: Diagrama de Gantt final del proyecto

La organización temporal del trabajo se desarrolló finalmente de la siguiente manera (véase la Figura 1.7):

- Febrero: se redactó la propuesta del Trabajo de Fin de Grado, la cual fue aceptada en el plazo de una semana.
- Marzo: la primera parte del mes se destinó a la implementación de algunas técnicas de CP en clasificación(LAC, APS y RAPS) sobre el conjunto de datos CIFAR-10. A mediados de mes se concedió acceso al clúster SLURM, lo que permitió comenzar la organización del proyecto, la implementación del núcleo del código y la configuración del entorno de trabajo mediante un proceso iterativo de prueba y error orientado a obtener una solución más cómoda y flexible.
- Abril: se llevó a cabo la búsqueda, revisión, organización y análisis de bibliografía, con especial atención a la literatura en AF. A mediados de mes se obtuvo acceso al conjunto de datos definitivo que sería utilizado en el proyecto. Fue necesario adaptar el núcleo de código previamente desarrollado, dedicándose varias semanas a la experimentación y mejora del modelo de red neuronal convolucional (CNN). Se aprovechó para organizar el código y subirlo a un repositorio.
- Mayo: a principios de mes se completó una primera versión del capítulo inicial (*Introducción*). Durante la primera mitad del mes se continuó con la optimización del entrenamiento e inferencia del modelo, en paralelo con la redacción del capítulo de Fundamentos teóricos.
- Junio: a comienzos de mes se obtuvo la primera versión completa del capítulo segundo (*Fundamentos teóricos*). En este momento se decidió centrar los esfuerzos en la parte de regresión, lo que condujo a la implementación de las técnicas de CP aplicadas a este contexto. Durante el proceso se identificó la necesidad de reformar nuevamente el núcleo del código, con el fin de reducir repeticiones y dotarlo de mayor flexibilidad, permitiendo mediante argumentos entrenar toda la red o únicamente la cabeza, seleccionar la técnica de CP, realizar inferencia, entre otras opciones. De forma paralela, se avanzó en la redacción del capítulo tercero (*Estado del arte*) y del capítulo cuarto (*Materiales y métodos*).
- Julio: a principios de mes se dispuso de una versión preliminar de la memoria que incluía la parte de regresión hasta la presentación de resultados, aunque sin discusión. Tras esto, el trabajo se orientó hacia la implementación de técnicas de CP para clasificación, en problemas derivados del enfoque de regresión. Asimismo, se desarrolló un sistema de almacenamiento más organizado de los resultados, de manera que

pudieran ser cargados posteriormente en un cuaderno Jupyter para su análisis.

- Agosto: se discutieron los resultados obtenidos tanto en regresión como en clasificación, se completaron apartados pendientes de la memoria y se llevaron a cabo ajustes finales. Finalmente, se redactó la conclusión y el *abstract*.

Finalmente, el trabajo se desarrolló entre el 24 de febrero y el 22 de agosto, considerando únicamente los días laborables, con excepción de los períodos del 4 al 8 de junio y del 3 al 10 de agosto, debido a vacaciones. Durante los días laborables se dedicó una media de 6 horas diarias, mientras que los sábados se trabajó aproximadamente 3 horas diarias.³

Teniendo en cuenta esta distribución, se puede estimar el total de horas trabajadas de la siguiente manera:

- Días laborables efectivos: $122 \text{ días} \times 6\text{h/día} = 732\text{h}$
- Sábados: $23 \text{ días} \times 3\text{h/día} = 69\text{h}$

Por tanto, el total aproximado de horas dedicadas al proyecto asciende a 801 horas, lo que supera por mucho la cifra teórica de 300 horas. Este tiempo de más se puede atribuir a varias causas principales:

- Complejidad del proyecto: Nunca antes me había enfrentado a un trabajo de esta complejidad, por lo que la planificación inicial no podía anticipar todas las dificultades técnicas y conceptuales.
- Adaptación y organización del código: La necesidad de modificar constantemente el núcleo del código para hacerlo más modular y flexible ha supuesto tiempo adicional no contemplado en la estimación inicial.
- Iteraciones y mejoras del modelo: Se llevaron a cabo múltiples iteraciones de entrenamiento y ajuste de hiperparámetros de los modelos CNN, así como experimentos para mejorar la eficiencia y la estabilidad de las predicciones, lo que incrementó considerablemente la carga de trabajo.
- Búsqueda, análisis y revisión bibliográfica: La investigación en literatura especializada, especialmente en antropología forense, materia en la que soy nuevo, requirió un tiempo prolongado de lectura, análisis y síntesis para incorporarlo a la memoria.

³Estimación realizada de manera aproximada.

- Circunstancias externas y aprendizaje: Ajustes en la planificación por cuestiones de salud, aprendizaje de nuevas herramientas (PyTorch, SLURM, Jupyter), problemas con el software (drivers de CUDA) y adaptaciones metodológicas también contribuyeron a la ampliación del tiempo dedicado.

1.5. Presupuesto del proyecto

En este apartado hacemos un ejercicio de cuánto hubiese costado desarrollar este trabajo

Se ha dispuesto de todos los materiales necesarios para la realización del proyecto de manera gratis. Aún así, en este apartado se hace una estimación del coste de desarrollar el trabajo ...

Este trabajo ha sido realizado con dos equipos independientes:

- **Ordenador portátil personal:** Asus Zephyrus G14, modelo GA401 de 2021, empleado principalmente para la redacción y compilación de este documento en L^AT_EX, así como el análisis exploratorio de datos y el tratamiento de resultados. El sistema operativo empleado es Linux Mint (versión 22.1). El portátil fue adquirido por 1100€ en marzo de 2022. Para la estimación de la amortización se ha considerado una vida útil de 4 años, criterio habitual en contabilidad empresarial y acorde con la obsolescencia tecnológica de este tipo de dispositivos:

$$\begin{aligned} \text{Coste imputado} &= \frac{\text{Precio de adquisición}}{\text{Vida útil}} \times \frac{\text{Tiempo de uso}}{\text{en el proyecto}} \\ &= \frac{1100 \text{ €}}{48 \text{ meses}} \times 6 \text{ meses} = 137.5 \text{ €} \end{aligned}$$

- **Clúster de computación DaSCI:** proporcionado por el Instituto de Ciencia de Datos e Inteligencia Artificial de la Universidad de Granada, al que se accede mediante conexión SSH.

El clúster cuenta con nodos diversos: con y sin GPU, con entre 40 y 60 CPUs y aproximadamente 122 GB de memoria RAM cada uno. Los nodos con GPU presentan diferentes modelos de gráfica: NVIDIA TITAN XP y NVIDIA Titan RTX, con CUDA 11.7 o superior. Todos los nodos cuentan con sistemas Linux compatibles con Pytorch. La implementación del código será adaptada para ejecutarse en cualquiera de los nodos con GPU.

El desarrollo del trabajo —tanto experimentación como puesta en marcha— se ha cobrado un total de 682.72 horas de GPU para el entrenamiento e inferencia de los modelos ML⁴.

Para simplificar la estimación del coste, se considera un único nodo con la GPU más económica, NVIDIA Titan XP, ya que los requisitos computacionales del proyecto no justificaban el uso de hardware más potente. La estimación del coste de uso de la GPU se basa en precios de referencia de servicios *cloud* equivalentes. La NVIDIA Titan XP no es una GPU de centro de datos, pero se aproxima —en rendimiento para operaciones F32 y memoria— a una NVIDIA Tesla P100, con un precio de referencia entre 1.2-1.5 € por hora. Asumiendo un valor medio de 1.35 €/h, el coste total imputado del uso de la GPU en el proyecto sería:

$$\begin{aligned}\text{Coste GPU} &= \text{Tiempo GPU} \times \text{Precio por tiempo} \\ &= 682.72 \text{ h} \times 1.35 \text{ €/h} = 921.7 \text{ €}\end{aligned}$$

Aquí me estoy adelantando en el trabajo, ya que las horas totales las he obtenido tras terminar el trabajo, pero no sé de qué manera podría haberla estimados antes de comenzado un trabajo que es de investigación y donde se pierde más tiempo probando y errando que ejecutando el código definitivo.

En cuanto al software, se ha recurrido exclusivamente a herramientas de código abierto y libre distribución:

- **Linux Mint:** es el sistema operativo del ordenador personal.
- **Visual Studio Code:** empleado como entorno de desarrollo integrado (IDE) y como interfaz de conexión al clúster mediante SSH.
- **TeX Live:** distribución de LATEX, utilizada para la redacción, compilación y maquetación del documento.
- **Python:** lenguaje de programación utilizado para la implementación de los algoritmos.
- **Jupyter Notebook:** para experimentación interactiva y análisis exploratorio de datos y resultados.
- **PyTorch:** framework de referencia en el desarrollo de modelos de aprendizaje profundo.
- **Matplotlib y Seaborn:** bibliotecas de visualización para la representación gráfica de resultados, métricas y distribuciones.

⁴Estas cifras de tiempo han sido obtenidas del clúster Slurm, donde se han registrado todas las horas consumidas por cada trabajo.

Finalmente, en cuanto a recursos humanos, el coste asociado a la mano de obra se divide en dos categorías: investigación (desarrollo del trabajo) y mantenimiento del clúster.

En cuanto a la investigación, aunque el trabajo ha sido realizado por el autor, se puede estimar un coste hipotético basado en horas dedicadas.

Respecto al mantenimiento del clúster, al tratarse de un recurso institucional y dado que su coste operativo ya estaría incluido en servicios comerciales equivalentes, no se imputa adicionalmente al proyecto.

El coste total estimado, considerando ..., asciende a ...

Qué número de horas y precio debería considerar?
El número de horas teóricas (300 horas) o reales (801)?

Completar

Bibliografía

- [1] American Anthropological Association. “What is Anthropology?” Consultado el 01/04/2025, American Anthropological Association. URL: <https://americananthro.org/learn-teach/what-is-anthropology/>. [Citado en pág. 1].
- [2] S. P. Nawrocki. “An Outline Of Forensic Anthropology.” Archivado del original (PDF) el 15 de junio de 2015. Consultado el 30 de abril de 2025. URL: <https://web.archive.org/web/20110615005707/>. [Citado en pág. 1].
- [3] S. N. Byers y C. A. Juarez, *Introduction to Forensic Anthropology*, 6.^a ed. Routledge, 2023. [Citado en págs. 1, 3, 4].
- [4] H. H. de Boer, S. Blau, T. Delabarre y L. H. and, “The role of forensic anthropology in disaster victim identification (DVI): recent developments and future prospects,” *Forensic Sciences Research*, vol. 4, n.^o 4, págs. 303-315, 2019. [Citado en pág. 2].
- [5] M. Prinz, A. Carracedo, W. Mayr, N. Morling, T. Parsons, A. Sajantila, R. Scheithauer, H. Schmitter y P. Schneider, “DNA Commission of the International Society for Forensic Genetics (ISFG): Recommendations regarding the role of forensic genetics for disaster victim identification (DVI),” *Forensic Science International: Genetics*, vol. 1, n.^o 1, págs. 3-12, 2007. [Citado en pág. 2].
- [6] J.-P. Beauthier, E. De Valck, P. Lefèvre y J. De Winne, “Mass Disaster Victim Identification: The Tsunami Experience,” *The Open Forensic Science Journal*, vol. 2, n.^o 1, págs. 54-62, 2009. [Citado en págs. 2, 3].
- [7] M. Skinner, D. Alempijevic y M. Djuric-Srejic, “Guidelines for International Forensic Bio-archaeology Monitors of Mass Grave Exhumations,” *Forensic Science International*, vol. 134, n.^o 2, págs. 81-92, 2003. [Citado en pág. 2].

- [8] J. A. Sanchis-Gimeno, J. Iglesias-Bexiga, M. E. Schwab, G. López-García, E. Ariza, A. Calpe, M. Mezquida, S. Nalla e I. Ercan, “Identification success rates in the post-Spanish Civil War mass graves located in the cemetery of Paterna, Spain: Meta-research on 15 mass graves with 933 subjects,” *Forensic Science International*, vol. 361, págs. 112-122, ago. de 2024. [Citado en pág. 2].
- [9] M. Baeta, C. Núñez, S. Cardoso, L. Palencia-Madrid, L. Herrasti, F. Etxeberria y M. M. de Pancorbo, “Digging up the recent Spanish memory: genetic identification of human remains from mass graves of the Spanish Civil War and posterior dictatorship,” *Forensic Science International: Genetics*, vol. 19, págs. 272-279, 2015. [Citado en pág. 2].
- [10] V. Ataliva, N. F. Bahamondes, C. M. Suárez y B. Rosignoli, “Arqueología Forense y prácticas genocidas del Cono Sur americano: reflexionando desde los confines,” *Revista de Arqueología Americana*, vol. 41, págs. 403-441, jun. de 2024. [Citado en pág. 2].
- [11] T. Tanaka, “International Humanitarian Law (IHL) and Forensic Document Examination,” *Journal of the American Society of Questioned Document Examiners*, vol. 23, n.º 1, 2020. [Citado en pág. 2].
- [12] T. Thompson y S. Black, *Forensic Human Identification: An Introduction*, 1.^a ed. Taylor & Francis, 2006. [Citado en pág. 3].
- [13] D. Higgins, A. B. Rohrlach, J. Kaidonis, G. Townsend y J. J. Austin, “Differential Nuclear and Mitochondrial DNA Preservation in Post-Mortem Teeth with Implications for Forensic and Ancient DNA Studies,” *PLoS One*, vol. 10, n.º 5, págs. 1-17, 2015. [Citado en pág. 3].
- [14] K. E. Latham y J. J. Miller, “DNA Recovery and Analysis from Skeletal Material in Modern Forensic Contexts,” *Forensic Sciences Research*, vol. 4, n.º 1, págs. 51-59, 2018. [Citado en pág. 3].
- [15] Scientific Working Group for Forensic Anthropology (SWGANTH). “Personal Identification.” Consultado el 25 de abril de 2025. URL: https://www.nist.gov/system/files/documents/2018/03/13/swganth_personal_identification.pdf. [Citado en pág. 3].
- [16] B. Marcante, L. Marino, N. E. Cattaneo, A. Delicati, P. Tozzo y L. Caenazzo, “Advancing Forensic Human Chronological Age Estimation: Biochemical, Genetic, and Epigenetic Approaches from the Last 15 Years: A Systematic Review,” *International Journal of Molecular Sciences*, vol. 26, n.º 7, 2025. [Citado en pág. 4].
- [17] A. Ross y S. Williams, “Ancestry Studies in Forensic Anthropology: Back on the Frontier of Racism,” *Biology*, vol. 10, n.º 7, pág. 602, 2021. [Citado en pág. 4].

- [18] A. Ross y M. Pilloud, “The need to incorporate human variation and evolutionary theory in forensic anthropology: A call for reform,” *American Journal of Physical Anthropology*, vol. 176, n.º 4, págs. 672-683, 2021. [Citado en pág. 4].
- [19] D. Flouri, A. Alifragki, J. Gómez García-Donas y E. Kranioti, “Ancestry Estimation: Advances and Limitations in Forensic Applications,” *Research and Reports in Forensic Medical Science*, vol. 12, págs. 13-24, 2022. [Citado en pág. 4].
- [20] P. Mesejo, R. Martos, Ó. Ibáñez, J. Novo y M. Ortega, “A Survey on Artificial Intelligence Techniques for Biomedical Image Analysis in Skeleton-Based Forensic Human Identification,” *Applied Sciences*, vol. 10, n.º 14, pág. 4703, 2020. [Citado en pág. 4].
- [21] A. Schmeling, R. B. Dettmeyer, E. Rudolf, V. Vieth y G. Gescrick, “Forensic Age Estimation,” *Deutsches Arzteblatt international*, vol. 113, n.º 4, págs. 44-50, 2016. [Citado en pág. 5].
- [22] S. Nakhaeizadeh, I. E. Dror y R. M. Morgan, “Cognitive bias in forensic anthropology: Visual assessment of skeletal remains is susceptible to confirmation bias,” *Science & Justice*, vol. 54, n.º 3, págs. 208-214, 2014. [Citado en pág. 5].
- [23] G. S. Cooper y V. Meterko, “Cognitive bias research in forensic science: A systematic review,” *Forensic Science International*, vol. 297, págs. 35-46, 2019. [Citado en pág. 5].
- [24] N. R. Langley, L. M. Jantz, S. McNulty, H. Maijanen, S. D. Ousley y R. L. Jantz, “Error quantification of osteometric data in forensic anthropology,” *Forensic Science International*, vol. 287, págs. 183-189, 2018. [Citado en pág. 5].
- [25] D. H. Ubelaker y C. M. DeGaglia, “Population variation in skeletal sexual dimorphism,” *Forensic Science International*, vol. 278, 407.e1-407.e7, 2017. [Citado en pág. 5].
- [26] F. Curate, C. Umbelino, A. Perinha, C. Nogueira, A. Silva y E. Cunha, “Sex determination from the femur in Portuguese populations with classical and machine-learning classifiers,” *Journal of Forensic and Legal Medicine*, vol. 52, págs. 75-81, 2017. [Citado en pág. 5].
- [27] M. F. Darmawan, S. M. Yusuf, M. A. Rozi y H. Haron, “Hybrid PSO-ANN for sex estimation based on length of left hand bone,” en *2015 IEEE Student Conference on Research and Development (SCORed)*, IEEE, 2015, págs. 478-483. [Citado en pág. 5].

- [28] S. C. D. Pinto, P. Urbanová y R. M. Cesar-Jr, “Two-Dimensional Wavelet Analysis of Supraorbital Margins of the Human Skull for Characterizing Sexual Dimorphism,” *IEEE Transactions on Information Forensics and Security*, vol. 11, n.º 7, págs. 1542-1548, 2016. [Citado en pág. 5].
- [29] J. R. Kim, W. H. Shim, H. M. Yoon, S. H. Hong, J. S. Lee, Y. A. Choy y S. Kim, “Computerized Bone Age Estimation Using Deep Learning Based Program: Evaluation of the Accuracy and Efficiency,” *American Journal of Roentgenology*, vol. 209, n.º 6, págs. 1374-1380, 2017. [Citado en pág. 5].
- [30] D. Larson, M. Chen, M. Lungren, S. Halabi, N. Stence y C. Langlotz, “Performance of a Deep-Learning Neural Network Model in Assessing Skeletal Maturity on Pediatric Hand Radiographs,” *Radiology*, vol. 287, págs. 313-322, 2018. [Citado en pág. 5].
- [31] H. Lee, S. Tajmir, M. Zissen, B. Yeshiwas, T. Alkasab, G. Choy y S. Do, “Fully Automated Deep Learning System for Bone Age Assessment,” *Journal of digital imaging*, vol. 30, págs. 427-441, 2017. [Citado en pág. 5].
- [32] L. Ferrante y R. Cameriere, “Statistical methods to assess the reliability of measurements in procedures for forensic age estimation,” *International Journal of Legal Medicine*, vol. 123, n.º 4, págs. 277-283, 2009. [Citado en pág. 5].
- [33] R. Verma, K. Krishan, D. Rani, A. Kumar y V. Sharma, “Stature estimation in forensic examinations using regression analysis: A likelihood ratio perspective,” *Forensic Science International: Reports*, vol. 2, pág. 100 069, 2020. [Citado en págs. 5, 6].
- [34] M. Štepanovský, Z. Buk, A. Pilmann Kotěrová, J. Brůžek, Š. Bejdová, N. Techataweewan y J. Velemínská, “Application of machine-learning methods in age-at-death estimation from 3D surface scans of the adult acetabulum,” *Forensic science international*, vol. 365, pág. 112 272, 2024. [Citado en pág. 5].
- [35] A. Heinrich, “Accelerating computer vision-based human identification through the integration of deep learning-based age estimation from 2 to 89 years,” *Sci Rep*, vol. 14, pág. 4195, 2024. [Citado en pág. 5].
- [36] S. Park, S. Yang, J. Kim, J. Kang, J. Kim, K. Huh, S. Lee, W. Yi y M. Heo, “Automatic and robust estimation of sex and chronological age from panoramic radiographs using a multi-task deep learning network: a study on a South Korean population,” *Int J Legal Med*, vol. 138, págs. 1741-1757, 2024. [Citado en pág. 5].

- [37] K. Imaizumi, S. Usui, K. Taniguchi, Y. Ogawa, T. Nagata, K. Kaga, H. Hayakawa y S. Shiotani, “Development of an age estimation method for bones based on machine learning using post-mortem computed tomography images of bones,” *Forensic Imaging*, vol. 26, pág. 200477, 2021. [Citado en pág. 5].
- [38] J. Venema, D. Peula, J. Irurita y P. Mesejo, “Employing deep learning for sex estimation of adult individuals using 2D images of the humerus,” *Neural Comput & Applic*, vol. 35, págs. 5987-5998, 2022. [Citado en pág. 5].
- [39] Ministerio del Interior de España, “Informe anual sobre personas desaparecidas 2025,” Ministerio del Interior, inf. téc., 2025. [Citado en págs. 6, 7].
- [40] F. Etxeberria, *Las exhumaciones de la Guerra Civil y la dictadura franquista 2000-2019: Estado actual y recomendaciones de futuro*. Madrid, España: Secretaría de Estado de Memoria Democrática, 2020, ISBN: 978-84-7471-146-2. URL: https://www.mpr.gob.es/servicios/publicaciones/Documents/Exhumaciones_Guerra_Civil_accesible_BAJA.pdf. [Citado en pág. 6].
- [41] Fiscalía General del Estado, “Memoria de la Fiscalía General del Estado 2024,” Fiscalía General del Estado, Madrid, España, inf. téc., 2024. [Citado en págs. 6, 8].
- [42] Fiscalía General del Estado, “Memoria de la Fiscalía General del Estado 2019,” Fiscalía General del Estado, Madrid, España, inf. téc., 2019. [Citado en págs. 6, 8].
- [43] Fiscalía General del Estado, “Memoria de la Fiscalía General del Estado 2016,” Fiscalía General del Estado, Madrid, España, inf. téc., 2016. [Citado en págs. 6, 8].
- [44] Fiscalía General del Estado, “Memoria de la Fiscalía General del Estado 2013,” Fiscalía General del Estado, Madrid, España, inf. téc., 2013. [Citado en págs. 6, 8].
- [45] S. Cordner y M. Tidball-Binz, “Humanitarian forensic action — Its origins and future,” *Forensic Science International*, vol. 279, págs. 65-71, 2017. [Citado en pág. 7].
- [46] M. V. Tidball-Binz y S. M. Cordner, “Humanitarian forensic action: A new forensic discipline helping to implement international law and construct peace,” *WIREs Forensic Science*, 2021. [Citado en pág. 7].
- [47] D. H. Ubelaker y H. Khosrowshahi, “Estimation of age in forensic anthropology: historical perspective and recent methodological advances,” *Forensic Sciences Research*, vol. 4, n.º 1, págs. 1-9, 2019.

- [48] C. O. Lovejoy, R. S. Meindl, T. R. Pryzbeck y R. P. Mensforth, “Chronological metamorphosis of the auricular surface of the ilium: A new method for the determination of adult skeletal age at death,” *American journal of physical anthropology*, vol. 68, págs. 15-28, 1985.
- [49] M. Y. İşcan, S. R. Loth y R. K. Wright, “Metamorphosis at the sternal rib end: A new method to estimate age at death in white males,” *American Journal of Physical Anthropology*, vol. 65, n.º 2, págs. 147-156, 1984.
- [50] R. S. Meindl y C. O. Lovejoy, “Ectocranial suture closure: A revised method for the determination of skeletal age at death based on the lateral-anterior sutures,” *American Journal of Physical Anthropology*, vol. 68, n.º 1, págs. 57-66, 1985.
- [51] C. E. Merritt, “The influence of body size on adult skeletal age estimation methods,” *American Journal of Physical Anthropology*, vol. 156, n.º 1, págs. 35-57, 2015.
- [52] D. J. Wescott y J. L. Drew, “Effect of obesity on the reliability of age-at-death indicators of the pelvis,” *American Journal of Physical Anthropology*, vol. 156, n.º 4, págs. 595-605, 2015.
- [53] H. Garvin y N. Passalacqua, “Current Practices by Forensic Anthropologists in Adult Skeletal Age Estimation,” *Journal of forensic sciences*, vol. 57, págs. 427-433, 2011.
- [54] S. Aja-Fernández, R. de Luis-García, M. Martín-Fernández y C. Alberola-López, “A computational TW3 classifier for skeletal maturity assessment. A Computing with Words approach,” *Journal of Biomedical Informatics*, vol. 37, n.º 2, págs. 99-107, 2004.
- [55] D. Štern, C. Payer y M. Urschler, “Automated age estimation from MRI volumes of the hand,” *Medical Image Analysis*, vol. 58, pág. 101 538, 2019.
- [56] L. Porto, L. Lima, A. Franco, D. Pianto, C. Machado y F. Vidal, “Estimating sex and age from a face: a forensic approach using machine learning based on photo-anthropometric indexes of the Brazilian population,” *International journal of legal medicine*, vol. 134(6), págs. 2239-2259, 2020.
- [57] M. A. Bidmos, O. I. Olateju, S. Latiff, T. Rahman y M. E. Chowdhury, “Machine learning and discriminant function analysis in the formulation of generic models for sex prediction using patella measurements,” *International Journal of Legal Medicine*, vol. 137, n.º 2, págs. 471-485, 2023.

- [58] M. J. Berst, L. Dolan, M. M. Bogdanowicz, M. A. Stevens, S. Chow y E. A. Brandser, "Effect of knowledge of chronologic age on the variability of pediatric bone age determined using the Greulich and Pyle standards," *American Journal of Roentgenology*, vol. 176, n.º 2, págs. 507-510, 2001.
- [59] D. D. Martin, D. Deusche, R. Schweizer, G. Binder, H. H. Thodberg y M. B. Ranke, "Clinical application of automated Greulich-Pyle bone age determination in children with short stature," *Pediatric radiology*, vol. 39, págs. 598-607, 2009.
- [60] D. D. Martin, K. Meister, R. Schweizer, M. B. Ranke, H. H. Thodberg y G. Binder, "Validation of automatic bone age rating in children with precocious and early puberty," 2011.
- [61] H. H. Thodberg, S. Kreiborg, A. Juul y K. D. Pedersen, "The BoneXpert method for automated determination of skeletal maturity," *IEEE transactions on medical imaging*, vol. 28, n.º 1, págs. 52-66, 2008.
- [62] R. R. van Rijn, M. H. Lequin y H. H. Thodberg, "Automatic determination of Greulich and Pyle bone age in healthy Dutch children," *Pediatric radiology*, vol. 39, págs. 591-597, 2009.
- [63] D. D. Martin, K. Sato, M. Sato, H. H. Thodberg y T. Tanaka, "Validation of a new method for automated determination of bone age in Japanese children," *Hormone research in paediatrics*, vol. 73, n.º 5, págs. 398-404, 2010.
- [64] H. H. Thodberg y L. Sävendahl, "Validation and reference values of automated bone age determination for four ethnicities," *Academic radiology*, vol. 17, n.º 11, págs. 1425-1432, 2010.
- [65] R. Cameriere, L. Ferrante y M. Cingolani, "Age estimation in children by measurement of open apices in teeth," *International journal of legal medicine*, vol. 120, págs. 49-52, 2006.
- [66] S. Brooks y J. M. Suchey, "Skeletal age determination based on the os pubis: a comparison of the Acsádi-Nemeskéri and Suchey-Brooks methods," *Human evolution*, vol. 5, págs. 227-238, 1990.
- [67] E. Baccino, L. Sinfield, S. Colomb, T. P. Baum y L. Martrille, "The two step procedure (TSP) for the determination of age at death of adult human remains in forensic cases," *Forensic science international*, vol. 244, págs. 247-251, 2014.
- [68] N. G. Rao, N. N. Rao, M. Pai y M. Shashidhar Kotian, "Mandibular canine index — A clue for establishing sex identity," *Forensic Science International*, vol. 42, n.º 3, págs. 249-254, 1989.

- [69] A. P. Indira, A. Markande y M. P. David, “Mandibular ramus: An indicator for sex determination-A digital radiographic study,” *Journal of forensic dental sciences*, vol. 4, n.º 2, págs. 58-62, 2012.
- [70] J. E. Buikstra, “Standards for data collection from human skeletal remains,” *Arkansas archaeological survey research series*, vol. 44, pág. 44, 1994.
- [71] N. Marquez-Grant, “An overview of age estimation in forensic anthropology: perspectives and practical considerations,” *Annals of human biology*, vol. 42, n.º 4, págs. 308-322, 2015.
- [72] D. Stern, T. Ebner, H. Bischof, S. Grassegger, T. Ehammer y M. Urschler, “Fully automatic bone age estimation from left hand MR images,” en *Medical Image Computing and Computer-Assisted Intervention-MICCAI 2014: 17th International Conference, Boston, MA, USA*, Springer, vol. 17(Pt II), 2014, págs. 220-227.
- [73] L. Scheuer y S. Black, *The juvenile skeleton*, 1.^a ed. Elsevier, 2004.
- [74] D. H. Ubelaker, “Forensic Anthropology: Methodology and Diversity of Applications,” en *Biological Anthropology of the Human Skeleton*. John Wiley & Sons, Ltd, 2018, cap. 2, págs. 43-71.
- [75] L. Scheuer y S. Black, *Developmental Juvenile Osteology*, 1.^a ed. Academic Press, 2000.
- [76] J. Adserias-Garriga, *Age estimation: a multidisciplinary approach*. Academic Press, 2019.
- [77] A. Turing, “I.—COMPUTING MACHINERY and INTELLIGENCE,” *Mind*, vol. LIX, n.º 236, págs. 433-460, 1950.
- [78] A. L. Samuel, “Some Studies in Machine Learning Using the Game of Checkers,” *IBM Journal of Research and Development*, vol. 3, n.º 3, págs. 210-229, 1959.
- [79] F. Rosenblatt, “The perceptron: a probabilistic model for information storage and organization in the brain,” *Psychological Review*, vol. 65(6), págs. 386-408, 1958.
- [80] W. S. McCulloch y W. Pitts, “A logical calculus of the ideas immanent in nervous activity,” *The bulletin of mathematical biophysics*, vol. 5, n.º 4, págs. 115-133, 1943.
- [81] J. R. Quinlan, “Induction of decision trees,” *Machine learning*, vol. 1, págs. 81-106, 1986.
- [82] D. E. Rumelhart, G. E. Hinton y R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, págs. 533-536, 1986.

- [83] S. Chen, E. Dobriban y J. Lee, “Invariance reduces Variance: Understanding Data Augmentation in Deep Learning and Beyond,” *ArXiv*, 2019. URL: <https://api.semanticscholar.org/CorpusID:198895147>.
- [84] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever y R. Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” *Journal of Machine Learning Research*, vol. 15, n.^o 56, págs. 1929-1958, 2014.
- [85] J. Tompson, R. Goroshin, A. Jain, Y. LeCun y C. Bregler, *Efficient Object Localization Using Convolutional Networks*, 2015. URL: <http://arxiv.org/abs/1411.4280>.
- [86] N. S. Keskar, D. Mudigere, J. Nocedal, M. Smelyanskiy y P. T. P. Tang, *On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima*, 2017. URL: <https://arxiv.org/abs/1609.04836>.
- [87] L. Bottou, “Large-Scale Machine Learning with Stochastic Gradient Descent,” *Proc. of COMPSTAT’2010*, págs. 177-186, 2010.
- [88] S. Ioffe y C. Szegedy, *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*, 2015. URL: <https://arxiv.org/abs/1502.03167>.
- [89] S. Santurkar, D. Tsipras, A. Ilyas y A. Madry, *How Does Batch Normalization Help Optimization?* 2019. URL: <https://arxiv.org/abs/1805.11604>.
- [90] S. Arora, Z. Li y K. Lyu, *Theoretical Analysis of Auto Rate-Tuning by Batch Normalization*, 2018. URL: <https://arxiv.org/abs/1812.03981>.
- [91] M. Sesia y E. J. Candès, “A comparison of some conformal quantile regression methods,” *Stat*, vol. 9, n.^o 1, e261, 2020.
- [92] T. Gneiting y A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” *Journal of the American statistical Association*, vol. 102, n.^o 477, págs. 359-378, 2007.
- [93] V. Nemanic, L. Biggio, X. Huan, Z. Hu, O. Fink, A. Tran, Y. Wang, X. Zhang y C. Hu, “Uncertainty quantification in machine learning for engineering design and health prognostics: A tutorial,” *Mechanical Systems and Signal Processing*, vol. 205, pág. 110796, 2023.
- [94] E. Begoli, T. Bhattacharya y D. Kusnezov, “The need for uncertainty quantification in machine-assisted medical decision making,” *Nature Machine Intelligence*, vol. 1, n.^o 1, págs. 20-23, 2019.

- [95] P. P. Angelov, E. A. Soares, R. Jiang, N. I. Arnold y P. M. Atkinson, “Explainable artificial intelligence: an analytical review,” *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 11, n.º 5, e1424, 2021.
- [96] S. Ali, T. Abuhmed, S. El-Sappagh, K. Muhammad, J. M. Alonso-Moral, R. Confalonieri, R. Guidotti, J. Del Ser, N. Díaz-Rodríguez y F. Herrera, “Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence,” *Information fusion*, vol. 99, pág. 101 805, 2023.
- [97] M. Abdar, F. Pourpanah, S. Hussain, D. Rezazadegan, L. Liu, M. Ghavamzadeh, P. Fieguth, X. Cao, A. Khosravi, U. R. Acharya et al., “A review of uncertainty quantification in deep learning: Techniques, applications and challenges,” *Information fusion*, vol. 76, págs. 243-297, 2021.
- [98] A. F. Psaros, X. Meng, Z. Zou, L. Guo y G. E. Karniadakis, “Uncertainty quantification in scientific machine learning: Methods, metrics, and comparisons,” *Journal of Computational Physics*, vol. 477, pág. 111 902, 2023.
- [99] T. Miller, “Explanation in artificial intelligence: Insights from the social sciences,” *Artificial intelligence*, vol. 267, págs. 1-38, 2019.
- [100] M. Salvi, S. Seoni, A. Campagner, A. Gertych, U. R. Acharya, F. Molinari y F. Cabitza, “Explainability and uncertainty: Two sides of the same coin for enhancing the interpretability of deep learning models in healthcare,” *International Journal of Medical Informatics*, vol. 197, pág. 105 846, 2025.
- [101] I. Loshchilov y F. Hutter, “Decoupled weight decay regularization,” *arXiv preprint arXiv:1711.05101*, 2017.
- [102] L. N. Smith, “A disciplined approach to neural network hyper-parameters: Part 1—learning rate, batch size, momentum, and weight decay,” *arXiv preprint arXiv:1803.09820*, 2018.
- [103] D. Prinster, S. Stanton, A. Liu y S. Saria, “Conformal validity guarantees exist for any data distribution (and how to find them),” *arXiv preprint arXiv:2405.06627*, 2024.
- [104] D. H. Wolpert y W. G. Macready, “No free lunch theorems for optimization,” *IEEE transactions on evolutionary computation*, vol. 1, n.º 1, págs. 67-82, 1997.
- [105] R. Foygel Barber, E. J. Candès, A. Ramdas y R. J. Tibshirani, “The limits of distribution-free conditional predictive inference,” *Information and Inference: A Journal of the IMA*, vol. 10, n.º 2, págs. 455-482, 2021.

- [106] I. Steinwart y A. Christmann, “Estimating conditional quantiles with the help of the pinball loss,” *Bernoulli*, vol. 17, n.º 1, págs. 221-225, 2011.
- [107] S. MacLaughlin, J. Bowman y L. Scheuer, “The relationship between biological and chronological age in the juvenile remains from St Bride’s Church, Fleet Street,” *Annals of Human Biology*, vol. 19, n.º 2, págs. 211-216, 1992.
- [108] R. F. Barber, E. J. Candes, A. Ramdas y R. J. Tibshirani, “Predictive inference with the jackknife+,” *The Annals of Statistics*, vol. 49, n.º 1, págs. 486-507, 2021.
- [109] H. Linusson, U. Johansson y T. Löfström, “Signed-error conformal regression,” en *Advances in Knowledge Discovery and Data Mining: 18th Pacific-Asia Conference, PAKDD 2014, Tainan, Taiwan, May 13-16, 2014. Proceedings, Part I 18*, Springer, 2014, págs. 224-236.
- [110] K. Stankeviciute, A. M Alaa y M. van der Schaar, “Conformal time-series forecasting,” *Advances in neural information processing systems*, vol. 34, págs. 6216-6228, 2021.
- [111] R. Laxhammar y G. Falkman, “Inductive conformal anomaly detection for sequential detection of anomalous sub-trajectories,” *Annals of Mathematics and Artificial Intelligence*, vol. 74, págs. 67-94, 2015.
- [112] U. Johansson, H. Linusson, T. Löfström y H. Boström, “Model-agnostic nonconformity functions for conformal classification,” en *2017 International Joint Conference on Neural Networks (IJCNN)*, IEEE, 2017, págs. 2072-2079.
- [113] Y. LeCun, Y. Bengio y G. Hinton, “Deep Learning,” *Nature*, vol. 521, págs. 436-44, 2015.
- [114] F. Bre, J. Gimenez y V. Fachinotti, “Prediction of wind pressure coefficients on building surfaces using Artificial Neural Networks,” *Energy and Buildings*, vol. 158, 2017.
- [115] H. W. Loh, C. P. Ooi, S. Seoni, P. D. Barua, F. Molinari y U. R. Acharya, “Application of explainable artificial intelligence for health-care: A systematic review of the last decade (2011–2022),” *Computer methods and programs in biomedicine*, vol. 226, pág. 107161, 2022.
- [116] P. Domingos, *The Master Algorithm: How the Quest for the Ultimate Learning Machine Will Remake Our World*. USA: Penguin Books Limited, 2015.
- [117] S. Russell y P. Norvig, *Artificial Intelligence: A Modern Approach*, 4rd. Prentice Hall Press, 2021.
- [118] C. M. Bishop, *Pattern Recognition and Machine Learning*. Berlin, Heidelberg: Springer-Verlag, 2006.

- [119] E. Alpaydin, *Introduction to Machine Learning*, 2nd. The MIT Press, 2010.
- [120] P. J. Werbos, *The roots of backpropagation: from ordered derivatives to neural networks and political forecasting*. USA: Wiley-Interscience, 1994.
- [121] K. P. Murphy, *Probabilistic Machine Learning: An introduction*. MIT Press, 2022.
- [122] R. Szeliski, *Computer Vision: Algorithms and Applications*, 1st. Berlin, Heidelberg: Springer-Verlag, 2010.
- [123] A. Zhang, Z. C. Lipton, M. Li y A. J. Smola, *Dive into Deep Learning*, 2021.
- [124] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016.
- [125] V. Vovk, A. Gammerman y G. Shafer, *Algorithmic learning in a random world*. Springer, 2005, vol. 29.
- [126] Red Hat, *Deep learning*, Consultado el 10/05/2025, 2023. URL: <https://www.redhat.com/es/topics/ai/what-is-deep-learning>.
- [127] Code World, *Understanding ML & DL in python*, Consultado el 19/05/2025, 2022. URL: <https://codeworld.tistory.com/2>.
- [128] NVIDIA, *Convolutional Neural Network*, Consultado el 21/05/2025, 2025. URL: <https://www.nvidia.com/en-eu/glossary/convolutional-neural-network/>.
- [129] G. Furnieles, *Sigmoid and SoftMax Functions in 5 minutes*, Consultado el 26/05/2025, 2022. URL: <https://towardsdatascience.com/sigmoid-and-softmax-functions-in-5-minutes-f516c80ea1f9/>.
- [130] J. G. Sam Lau y D. Nolan, *Cross Validation*, Consultado el 26/05/2025, 2023. URL: https://learningds.org/ch/16/ms_cv.html.
- [131] V. M. Vargas, D. Guijo-Rubio, P. A. Gutiérrez y C. Hervás-Martínez, “ReLU-Based Activations: Analysis and Experimental Study for Deep Learning,” en *Advances in Artificial Intelligence*, E. Alba, G. Luque, F. Chicano, C. Cotta, D. Camacho, M. Ojeda-Aciego, S. Montes, A. Troncoso, J. Riquelme y R. Gil-Merino, eds., Cham: Springer International Publishing, 2021, págs. 33-43.
- [132] M. Sato, J. Suzuki, H. Shindo e Y. Matsumoto, “Interpretable Adversarial Perturbation in Input Embedding Space for Text,” en *Proceedings of the 27th International Joint Conference on Artificial Intelligence (IJCAI 2018)*, Stockholm, Sweden: International Joint Conferences on Artificial Intelligence, 2018, págs. 4323-4330.

- [133] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li y L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” en *2009 IEEE conference on computer vision and pattern recognition*, IEEE, 2009, págs. 248-255.
- [134] S. Xie, R. Girshick, P. Dollár, Z. Tu y K. He, “Aggregated residual transformations for deep neural networks,” en *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, págs. 1492-1500.
- [135] A. Niculescu-Mizil y R. Caruana, “Predicting good probabilities with supervised learning,” en *Proceedings of the 22nd international conference on Machine learning*, 2005, págs. 625-632.
- [136] M. Zaffran, O. Féron, Y. Goude, J. Josse y A. Dieuleveut, “Adaptive conformal predictions for time series,” en *International Conference on Machine Learning*, PMLR, 2022, págs. 25 834-25 866.
- [137] C. Xu e Y. Xie, “Conformal prediction interval for dynamic time-series,” en *International Conference on Machine Learning*, PMLR, 2021, págs. 11 559-11 569.
- [138] Joint Committee for Guides in Metrology (JCGM), *Evaluation of measurement data — Guide to the expression of Uncertainty in Measurement (GUM)*, GUM 1995 with minor corrections, JCGM 100:2008, Consultado el 30/05/2025, JCGM, Sèvres, France, 2008. URL: https://www.bipm.org/documents/20126/2071204/JCGM_100_2008_E.pdf.
- [139] Joint Committee for Guides in Metrology (JCGM), *International vocabulary of metrology — Basic and general concepts and associated terms (VIM)*, VIM 2008 version with minor corrections, JCGM 200:2012, Consultado el 30/05/2025, JCGM, Sèvres, France, 2012. URL: https://www.bipm.org/documents/20126/2071204/JCGM_200_2012.pdf.
- [140] J. R. Berrendero. “Materiales del libro de Estadística,” visitado 2 de jun. de 2025. URL: <https://verso.mat.uam.es/~joser.berrendero/libro-est/>.
- [141] E. Hüllermeier y W. Waegeman, “Aleatoric and epistemic uncertainty in machine learning: an introduction to concepts and methods,” *Machine Learning*, vol. 110, págs. 457-506, 2021.
- [142] J. Gama, “A survey on learning from data streams: current and future trends,” *Progress in Artificial Intelligence*, vol. 1, págs. 45-55, 2012.
- [143] J. Vermorel. “Quantile Regression,” LOKAD Quantitive Supply Chain, visitado 2 de jun. de 2025. URL: <https://www.lokad.com/quantile-regression-time-series-definition/>.

- [144] R. Koenker, *Quantile Regression* (Econometric Society Monographs). Cambridge University Press, 2005.
- [145] S. T. Tokdar y J. B. Kadane, “Simultaneous linear quantile regression: a semiparametric Bayesian approach,” *Bayesian Analysis*, vol. 7, n.º 1, págs. 51-72, 2012.
- [146] J. Feldman y D. Kowal, “Bayesian Quantile Regression with Subset Selection: A Posterior Summarization Perspective,” *arXiv preprint arXiv:2311.02043*, 2023.
- [147] C. Guo, G. Pleiss, Y. Sun y K. Q. Weinberger, “On calibration of modern neural networks,” en *International conference on machine learning*, PMLR, 2017, págs. 1321-1330.
- [148] A. N. Angelopoulos y S. Bates, “A gentle introduction to conformal prediction and distribution-free uncertainty quantification,” *arXiv preprint arXiv:2107.07511*, 2021.
- [149] Scikit-learn-contrib MAPIE developers. “MAPIE: Model-Agnostic Prediction Interval Estimator.” Accessed: 2025-07-06. URL: <https://mapie.readthedocs.io/en/stable/>.
- [150] V. Vovk, “Cross-conformal predictors,” *Annals of Mathematics and Artificial Intelligence*, vol. 74, n.º 1, págs. 9-28, 2015.
- [151] M. Sadinle, J. Lei y L. Wasserman, “Least ambiguous set-valued classifiers with bounded error levels,” *Journal of the American Statistical Association*, vol. 114, n.º 525, págs. 223-234, 2019.
- [152] V. Vovk, D. Lindsay, I. Nouretdinov y A. Gammerman, “Mondrian confidence machine,” *Technical Report*, 2003.
- [153] Y. Romano, M. Sesia y E. Candes, “Classification with valid and adaptive coverage,” *Advances in neural information processing systems*, vol. 33, págs. 3581-3591, 2020.
- [154] A. Angelopoulos, S. Bates, J. Malik y M. I. Jordan, “Uncertainty sets for image classifiers using conformal prediction,” *arXiv preprint arXiv:2009.14193*, 2020.
- [155] J. Huang, H. Xi, L. Zhang, H. Yao, Y. Qiu y H. Wei, “Conformal prediction for deep classifier via label ranking,” *arXiv preprint arXiv:2310.06430*, 2023.
- [156] H. Papadopoulos, K. Proedrou, V. Vovk y A. Gammerman, “Inductive confidence machines for regression,” en *Machine learning: ECML 2002: 13th European conference on machine learning Helsinki, Finland, August 19–23, 2002 proceedings 13*, Springer, 2002, págs. 345-356.

- [157] Y. Romano, E. Patterson y E. Candès, “Conformalized quantile regression,” *Advances in neural information processing systems*, vol. 32, 2019.
- [158] D. Bethell, S. Gerasimou y R. Calinescu, “Robust uncertainty quantification using conformalised Monte Carlo prediction,” en *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, 2024, págs. 20 939-20 948.
- [159] R. Luo y Z. Zhou, “Conformal thresholded intervals for efficient regression,” en *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 39, 2025, págs. 19 216-19 223.

